Informe de segmentación de clientes minoristas

Análisis del notebook P7.ipynb

Objetivo

Comparar las segmentaciones generadas, evaluar su consistencia, sintetizar los hallazgos con visualizaciones y proponer usos comerciales accionables para cada segmento.

Base analizada: 8.068 registros y 11 variables originales; tras el preprocesamiento, la matriz transformada quedó en 28 variables.

Resumen ejecutivo

El notebook P7.ipynb aplica un flujo de segmentación no supervisada: limpieza, imputación, codificación de variables categóricas, escalamiento, reducción dimensional con PCA y t-SNE, y luego tres algoritmos de clusterización: K-Means, DBSCAN y clustering jerárquico.

Desde el punto de vista técnico, DBSCAN obtiene el mejor silhouette score cuando se usa la configuración manual (0,352) y aún más alto en la búsqueda automática (0,432). Sin embargo, la mejor configuración automática produce 79 clusters y 5.579 puntos de ruido, por lo que no es una solución comercialmente estable ni interpretable.

Para uso de negocio, la segmentación más defendible es K-Means con k=4. Aunque su silhouette es más bajo (0,148), entrega cuatro grupos interpretables, comparables entre sí y alineados con una lógica comercial clara. El clustering jerárquico refuerza esa lectura porque también converge a 4 grupos y obtiene un desempeño cercano (0,136).

Los perfiles K-Means muestran diferencias útiles en edad, experiencia laboral, tamaño familiar, estado civil, graduación y spending score. Esto permite traducir la segmentación a acciones concretas de marketing, fidelización, cross-sell y priorización de ofertas.

Comparación cuantitativa de modelos

Modelo	Parámetros	N° clusters	Ruido	Silhouette
K-Means	k = 4	4	0	0,1484
DBSCAN (manual)	eps = 1,7; min_samples = 3	2	57	0,3521
DBSCAN (automático)	eps = 0,5; min_samples = 10	79	5.579	0,4317
Jerárquico	n_clusters = 4; linkage = ward	4	0	0,1363

Lectura recomendada: el mejor valor métrico no siempre equivale a la mejor segmentación comercial. En este caso, DBSCAN automático maximiza separación interna, pero fragmenta demasiado la base y clasifica gran parte de los clientes como ruido.

Validación visual

K-Means muestra una estructura segmentada relativamente estable tanto en PCA como en t-SNE. La combinación de método del codo y silhouette justifica explorar varios k, aunque el notebook fija k=4 por interpretabilidad y comparación con la columna de referencia Segmentation.

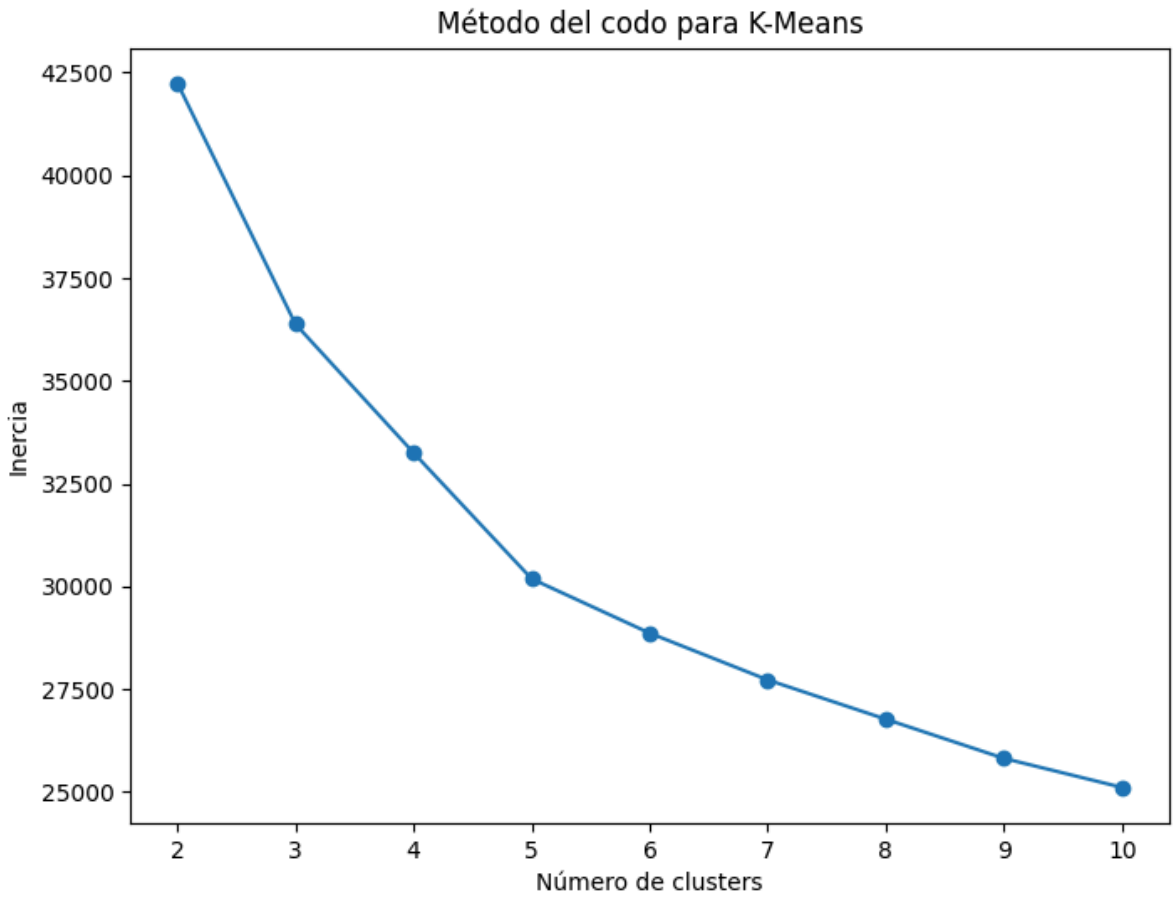

Figura 1. Método del codo para K-Means.

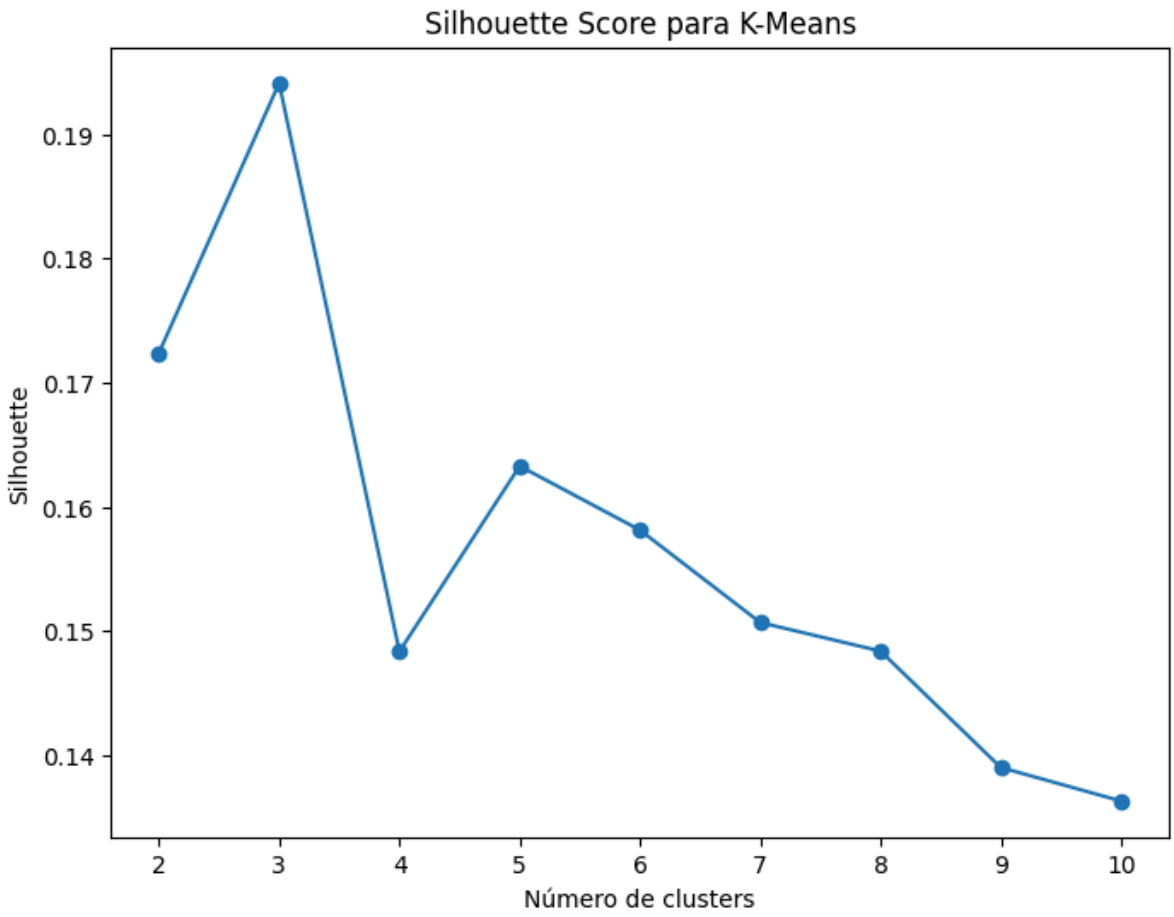

Figura 2. Silhouette score para distintos valores de k.

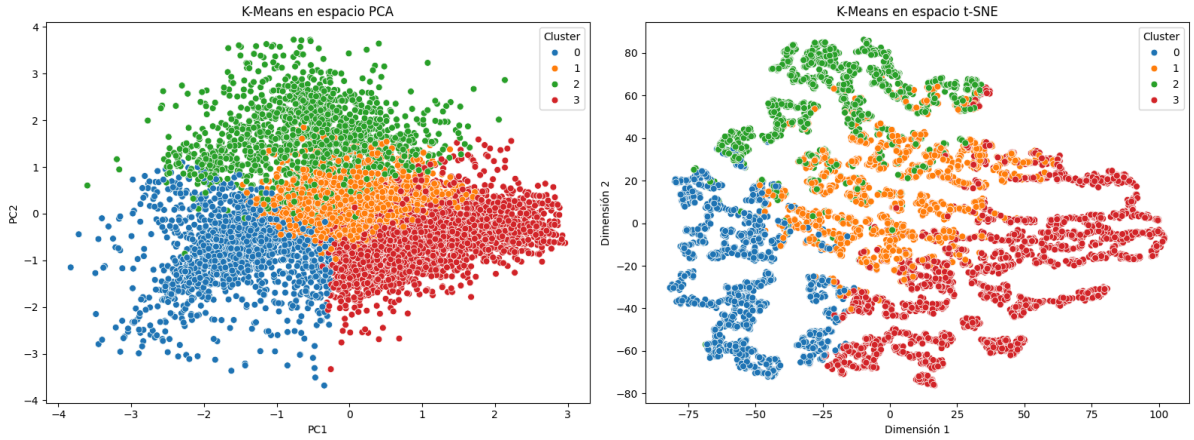

Figura 3. Clusters K-Means visualizados en PCA y t-SNE.

DBSCAN y clustering jerárquico

DBSCAN detecta estructuras y outliers, pero es altamente sensible a eps y min_samples. El gráfico de búsqueda evidencia que pequeñas variaciones cambian drásticamente la cantidad de clusters. Por eso conviene usarlo como herramienta complementaria para detectar densidades y anomalías, no como partición principal del negocio en este caso.

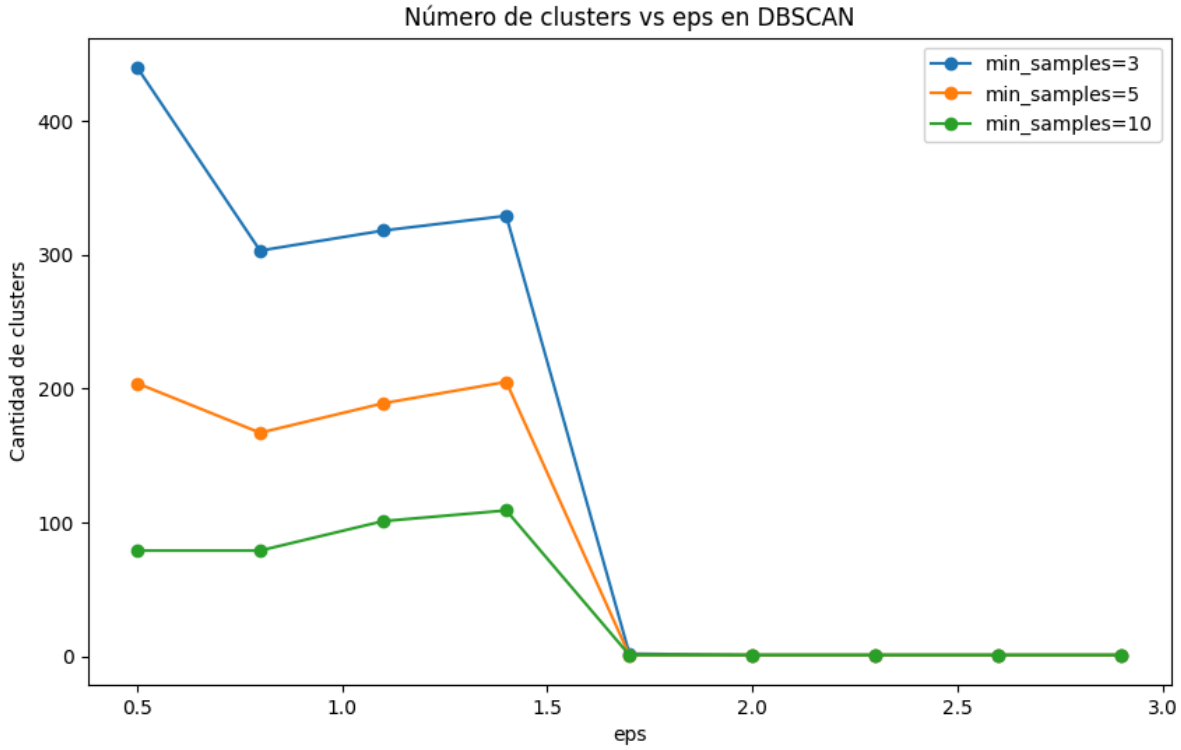

Figura 4. Sensibilidad del número de clusters ante distintos valores de eps.

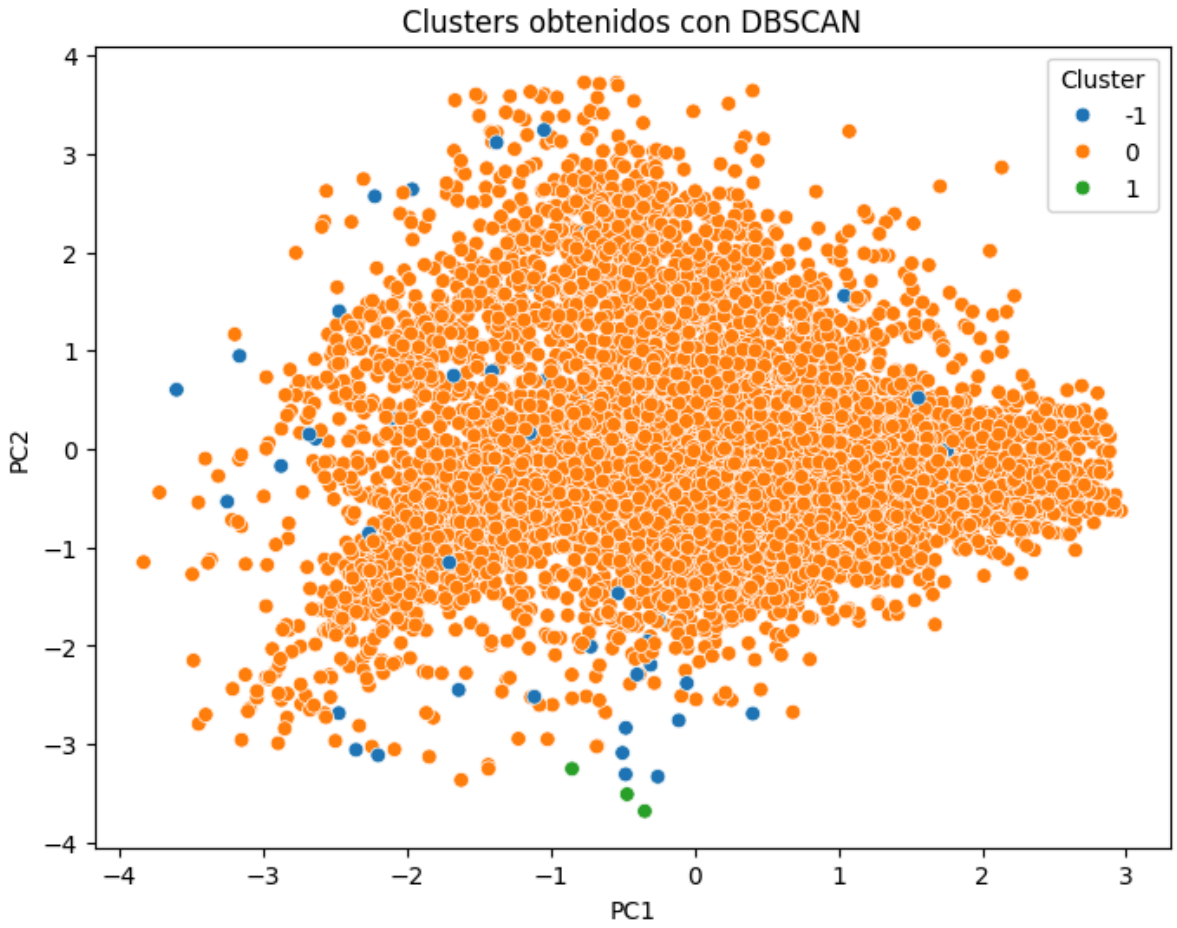

Figura 5. DBSCAN manual en espacio PCA.

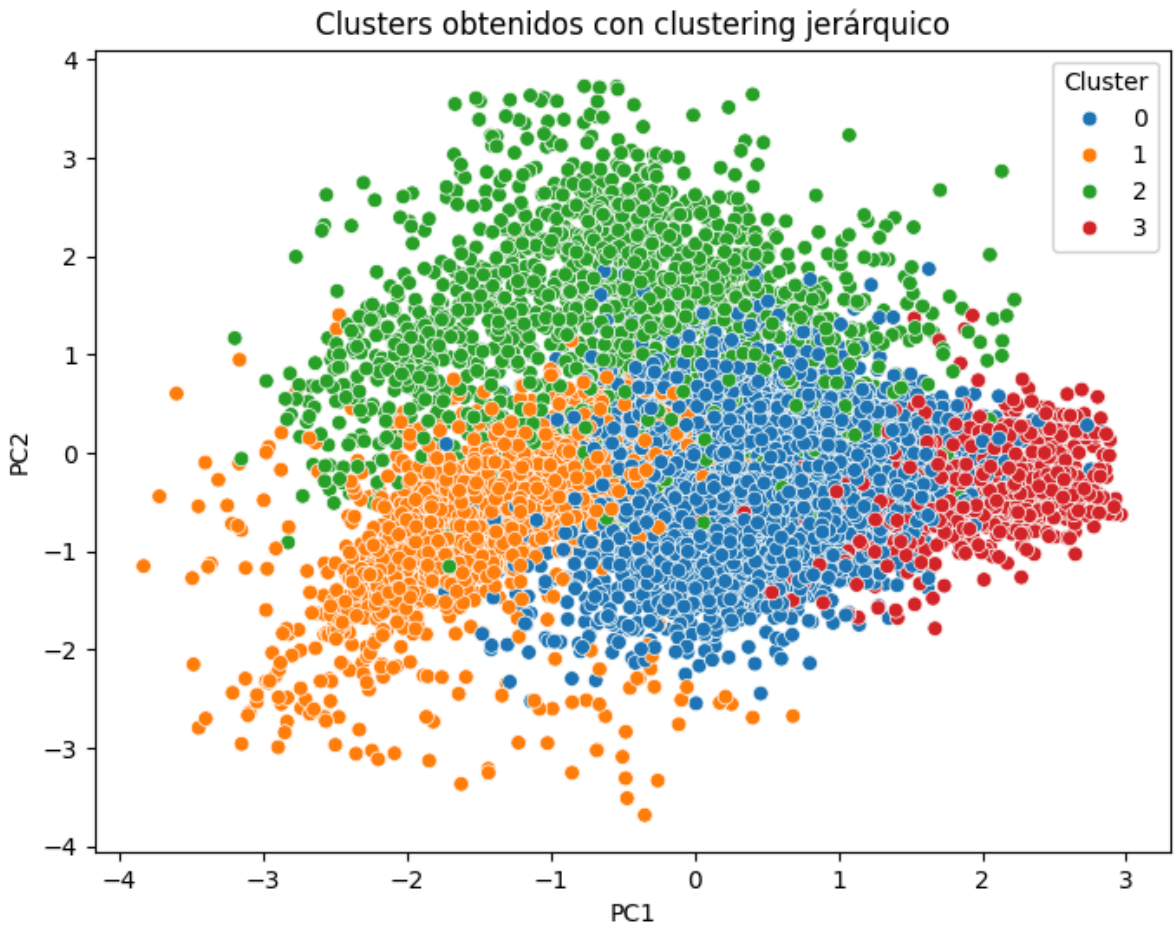

Figura 6. Clustering jerárquico en espacio PCA.

Evaluación de consistencia

- Consistencia entre métodos: K-Means y jerárquico convergen en una solución de 4 grupos, lo que sugiere una estructura central relativamente estable en la base.
- Consistencia métrica: K-Means (0,148) y jerárquico (0,136) presentan valores cercanos. Esto indica que ambos están capturando una separación moderada, típica de problemas reales con variables demográficas y de comportamiento.
- Consistencia visual: las proyecciones en PCA y t-SNE permiten observar separación parcial, pero también solapamientos. Eso refuerza que la segmentación es útil para el negocio, aunque no representa grupos perfectamente aislados.
- Consistencia comercial: los perfiles K-Means son legibles y diferentes entre sí. DBSCAN automático no es consistente con un uso comercial porque produce demasiada fragmentación y deja fuera a la mayoría de los clientes.

Perfiles de segmentos K-Means

Cluster	Edad media	Exp. laboral	Tamaño familiar	Spending dominante	Estado civil	Graduación	Lectura comercial
0	27,4	1,46	4,52	Low (89,1%)	No casados (84,4%)	No graduados (79,1%)	Jóvenes, hogares

							grandes, bajo gasto
1	38,5	1,03	1,72	Low (86,6%)	Más solteros que casados	Graduados (78,2%)	Adultos jóvenes, hogares pequeños, gasto contenido
2	37,9	8,47	2,45	Low (64,9%)	Leve mayoría casados	Graduados (69,4%)	Perfil laboral consolidado , gasto medio-bajo
3	59,0	0,98	2,79	Average/High (75,5%)	Casados (98,5%)	Graduados (72,9%)	Mayores, mayor poder de compra

Profesiones destacadas por cluster: el Cluster 0 concentra Healthcare (52,7%); el Cluster 1 se asocia más a Artist y Entertainment; el Cluster 2 combina Artist con mayor experiencia laboral; y el Cluster 3 destaca por mayor presencia de Lawyer y Executive, coherente con su mayor spending score.

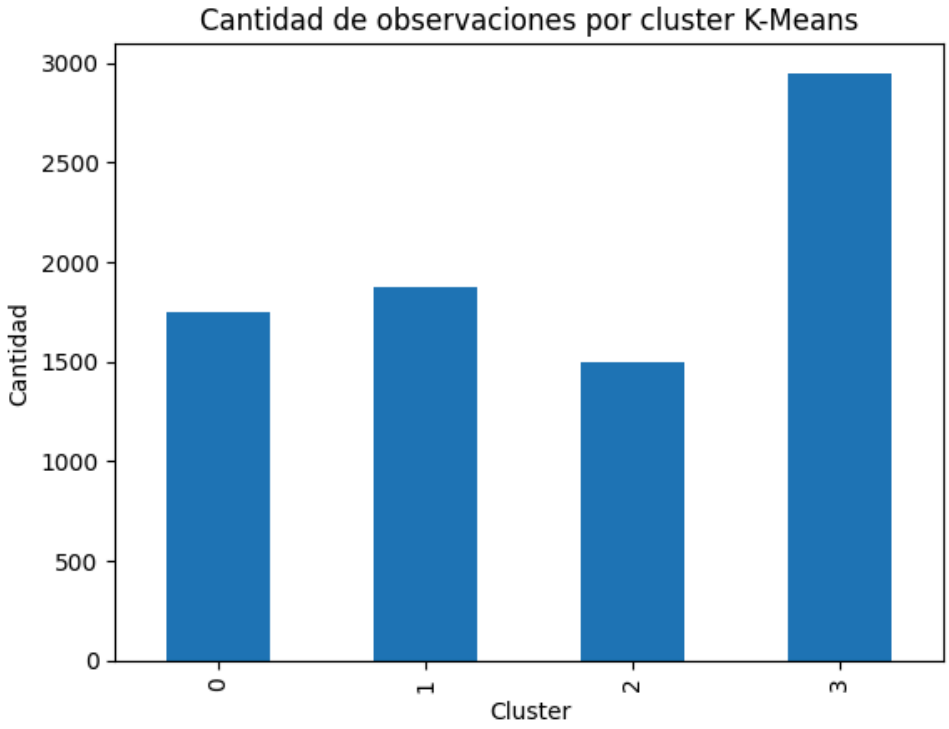

Figura 7. Tamaño de cada cluster K-Means.

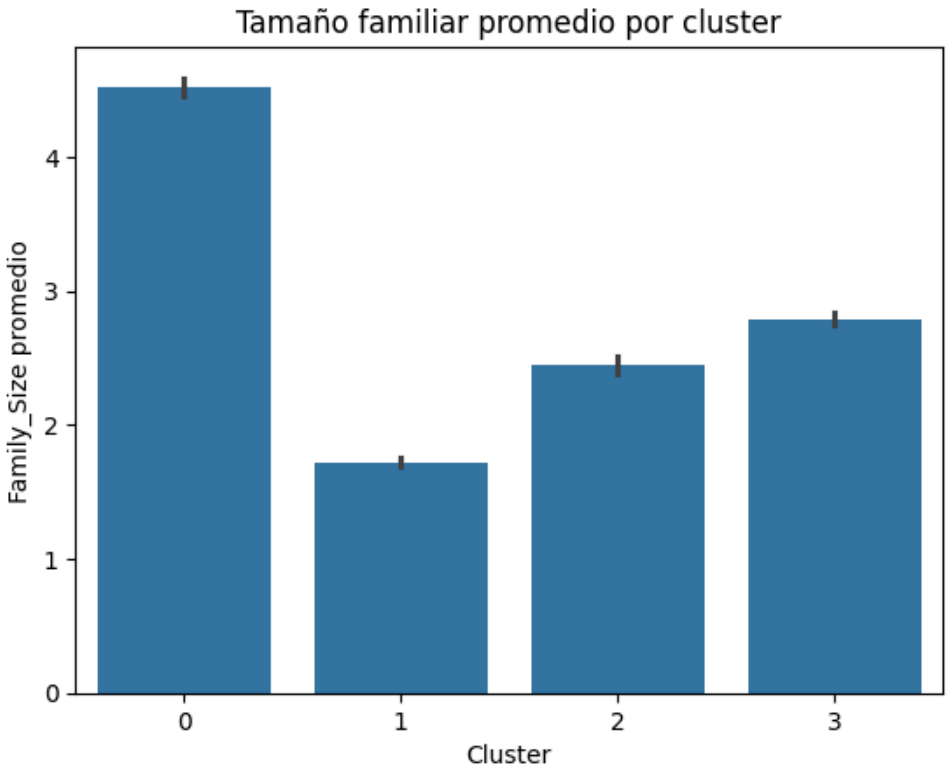

Figura 8. Tamaño familiar promedio por cluster.

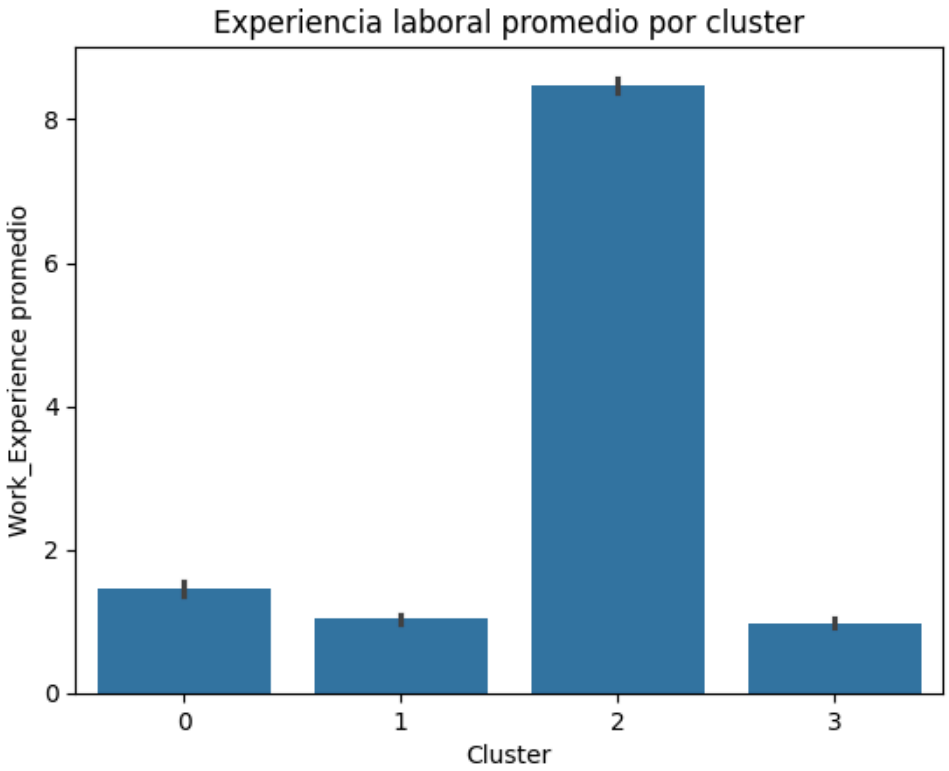

Figura 9. Experiencia laboral promedio por cluster.

Usos comerciales sugeridos

Segmento	Acciones recomendadas	Objetivo
Cluster 0: jóvenes, familias grandes, bajo gasto	Promociones familiares, packs, descuentos por volumen, campañas de inicio de ciclo de vida, ofertas omnicanal con sensibilidad a precio.	Aumentar ticket promedio y frecuencia con propuestas de valor accesibles.
Cluster 1: adultos jóvenes, hogares pequeños, graduados, bajo gasto	Campañas digitales segmentadas, recomendaciones personalizadas, pruebas gratuitas, bundles de conveniencia y remarketing.	Convertir interés en compra recurrente y mejorar engagement.
Cluster 2: clientes con alta experiencia laboral y gasto medio-bajo	Cross-sell de categorías complementarias, beneficios por recurrencia, mensajes orientados a eficiencia, calidad y ahorro de tiempo.	Elevar el gasto por cliente y migrarlos a categorías de mayor margen.
Cluster 3: mayores, casados, mayor spending score	Programas premium, atención preferente, productos de mayor valor, campañas de fidelización y experiencias exclusivas.	Retener clientes valiosos y maximizar margen y lifetime value.

Recomendación final

- Adoptar K-Means como segmentación principal para reporting, campañas y tableros ejecutivos.
- Usar clustering jerárquico como contraste metodológico para validar que la estructura de 4 grupos sigue siendo razonable.
- Usar DBSCAN de forma secundaria para detección de outliers, microsegmentos o clientes atípicos que requieran tratamiento especial.
- En una siguiente iteración, perfilar los clusters con variables de valor de cliente, frecuencia y mix de categorías para volverlos aún más accionables.

Conclusión: la evidencia sugiere que sí existe estructura segmentable en la base, pero la solución más útil para negocio no es la de mejor métrica aislada, sino la de mejor equilibrio entre separación, estabilidad e interpretabilidad. Bajo ese criterio, K-Means con 4 segmentos es la opción más sólida.